Технический отчёт: постановка задачи, данные и методика сравнения SFT и GRPO для управления агентом в MiniGrid EmptyEnv

Сергей Соловьев
Факультет компьютерных наук, НИУ ВШЭ
Москва, Россия
sesesolovev@edu.hse.ru sssolovjov@gmail.com
GitHub: github.com/SergeySolovyev
Сайт: sergeisolovev.com

4 марта 2026 г.

Аннотация

В работе спроектирован пайплайн дообучения vision-and-language модели (NanoVLM) для управления агентом в среде MiniGrid EmptyEnv. Рассматриваются три режима: (1) supervised fine-tuning (SFT) на экспертных траекториях; (2) GRPO при прямом выводе действия; (3) GRPO при формате вывода "текст + действие". Данный документ фиксирует постановку, данные, архитектурные решения и протокол экспериментов. Финальные численные результаты вынесены в отдельный документ (Part 2).

1 Постановка задачи и вклад

Цель — адаптировать NanoVLM к задаче управления агентом в MiniGrid EmptyEnv и сравнить:

- **SFT-бэйзлайн** на экспертных траекториях;
- **GRPO (action)**: RL-дообучение, где модель напрямую выдаёт действие;
- **GRPO (text+action)**: RL-дообучение, где модель генерирует короткое описание/план и действие.

Вклад Part 1: (i) описание эксперта и форматов данных; (ii) описание модели и парсинга действий; (iii) единый протокол обучения/оценки; (iv) фиксация статуса экспериментов.

2 Среда MiniGrid EmptyEnv и метрики

Среда EmptyEnv — сеточный мир с целевой клеткой (goal). Эпизод завершается при достижении цели либо по лимиту шагов.

Метрики качества:

- **Success rate**: доля успешных эпизодов.
- **Episode return**: средняя суммарная награда за эпизод.

3 Данные и эксперт

3.1 Экспертная политика

Для SFT-бэйзлайна используется алгоритмический эксперт в EmptyEnv (детерминированная навигационная эвристика: поворот к направлению цели + движение вперёд). Такой эксперт обеспечивает воспроизводимую

генерацию данных и сильный начальный сигнал для имитационного обучения.

3.2 Структура датасета

Каждый пример соответствует шагу траектории:

$$(\, o_t,\, x_t,\, y_t\,),$$

где o_t — визуальное наблюдение, x_t — текстовый промпт, y_t — целевой вывод.

(A) Direct action. `ACTION: <action_token>`

(B) Text + action.

```
STATE: ...
PLAN: ...
ACTION: <action_token>
```

4 Модель и форматы ввода/вывода

4.1 NanoVLM как политика

NanoVLM используется как генеративная политика: на вход подаются изображение и промпт, на выходе генерируется действие (или “текст+действие”).

4.2 Парсинг действия

Действие извлекается по ключу `ACTION:`. Для невалидного вывода применяется fallback-обработка, чтобы обеспечить устойчивое взаимодействие со средой.

5 Методы обучения

5.1 SFT

SFT оптимизирует кросс-энтропийный лосс по целевой последовательности (критичный токен — действие).

5.2 GRPO (action)

GRPO запускается из SFT-инициализации, использует группировку сэмплов, нормализацию преимуществ и регуляризацию для стабильности.

5.3 GRPO (text+action)

Модель генерирует краткий текст и действие; дополнительно может применяться мягкий бонус за корректный формат.

6 Статус экспериментов и публикация результатов

На момент подготовки данного документа выполняются/досчитываются финальные прогоны и агрегированные метрики.

С результатами можно ознакомиться по этой ссылке:

`NanoVLM MiniGrid Technical Report_Results.pdf`

Итоговые графики, таблицы качества, sample efficiency и выводы публикуются в отдельном документе **Part 2**.

7 Future Work

1. Curriculum learning по размеру карты/длине эпизода.
2. Балансировка демонстраций по типам состояний.
3. Data augmentation визуальных наблюдений.
4. Reward shaping и сравнение с базовой наградой.
5. Смешанное обучение (интерливинг SFT и GRPO).
6. OOD-оценка на новых конфигурациях среды.
7. Многократные прогоны с доверительными интервалами.