Технический отчёт: результаты экспериментов и анализ сравнения SFT и GRPO для управления агентом в MiniGrid EmptyEnv (Part 2, interim)

Сергей Соловьев
Факультет компьютерных наук, НИУ ВШЭ
Москва, Россия
sesesolovev@edu.hse.ru sssolovjov@gmail.com
GitHub: github.com/SergeySolovyev
Сайт: sergeisolovev.com

Аннотация

Документ продолжает Part 1 и фиксирует **фактически доступные** промежуточные результаты по пайплайну NanoVLM в MiniGrid EmptyEnv. На текущем срезе завершён SFT-бейзлайн (1 эпоха) и доступна частичная траектория GRPO (action) до update 10. Ветка GRPO (text+action) в сохранённых артефактах отсутствует, поэтому выводы носят промежуточный характер и явно ограничены текущим объёмом данных.

1 Фактический объём эксперимента

Part 1 зафиксировал постановку, данные, архитектуру и протокол. В данном документе приводятся численные результаты по тем этапам, которые реально выполнены и сохранены в артефактах.

Конфигурация среза:

- модель: `lusxvr/nanoVLM-222M`;
- среда: `MiniGrid-Empty-6x6`;
- оценка на контрольной выборке: 20 эпизодов на каждом checkpoint;
- SFT (`action`): завершён (epoch 1);
- GRPO (`action`): частично выполнен (update 10);
- GRPO (`text+action`): отсутствует в текущих артефактах.

Использованные источники данных:

- `artifacts/sft/history.csv`;
- `artifacts/grpo_action/history.csv`;
- `artifacts/sft/summary.json`.

2 Количественные результаты (промежуточные)

На этом этапе доступны только один SFT-checkpoint и один checkpoint GRPO (action), поэтому ниже приведены сводная таблица и соответствующая промежуточная визуализация.

2.1 Таблица метрик

Таблица 1: Доступные метрики по текущим checkpoint-ам

Метод	Точка прогресса	Train loss	Success rate	Avg return	Eval episodes
SFT (action)	epoch 1	0.01859	0.0500	0.0491	20
GRPO (action)	update 10	0.01189	0.0000	0.0000	20
GRPO (text+action)	–	N/A	N/A	N/A	N/A

2.2 Визуализация

Для текущего состояния доступна промежуточная столбчатая визуализация: `interim_comparison.png`.

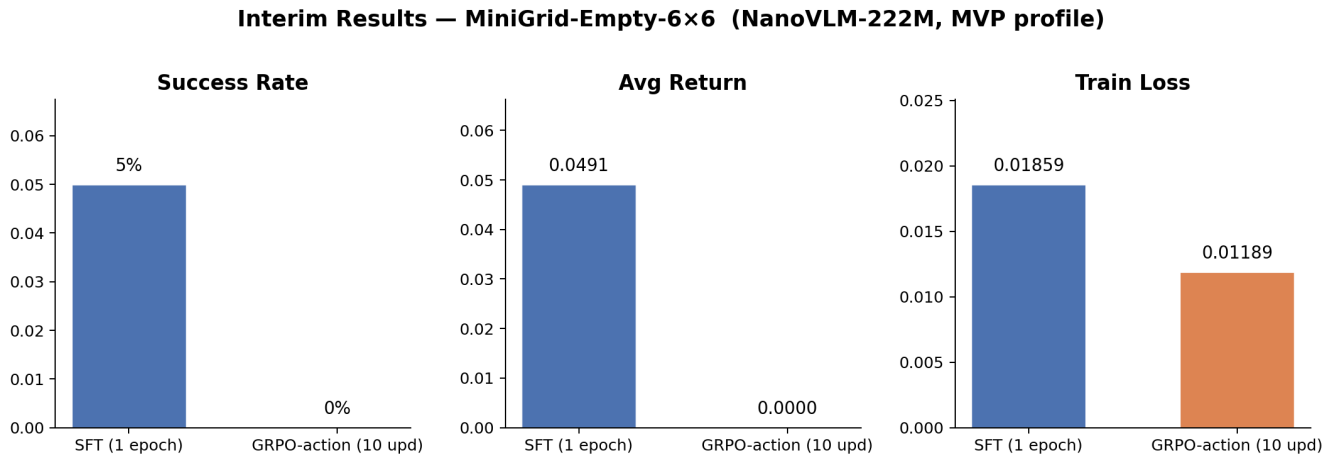

Рис. 1: Interim-сравнение SFT и GRPO (action) по доступным checkpoint-ам.

Поскольку в каждой завершённой ветке пока доступна только одна точка истории, полноценные кривые обучения (по времени/обновлениям) на данном этапе неинформативны.

3 Интерпретация и ограничения

Наблюдение 1. SFT даёт ненулевой, но слабый baseline (success rate = 5%).

Наблюдение 2. В доступном фрагменте GRPO (action) улучшение не зафиксировано к update 10 (success rate = 0.0, avg return = 0.0).

Наблюдение 3. Сравнение форматов вывода `action` vs `text+action` в данный момент сделать нельзя из-за отсутствия соответствующей траектории.

Ключевые ограничения:

- прерывания Colab-сессии (runtime disposal) привели к неполным логам обучения;
- доступная траектория RL слишком короткая для устойчивого вывода;
- Single-seed и короткий горизонт подразумевают высокую дисперсию оценок.

4 Sample efficiency: текущий статус

По требованиям задания нужен анализ sample efficiency (число эпизодов/шагов среды до порогового успеха). Для текущего среза:

- достижение порога корректно не наблюдается;
- ветка `text+action` отсутствует;
- итоговые значения sample efficiency на этом этапе: **N/A (interim)**.

5 Выводы (промежуточные) и следующие шаги

Текущие результаты являются предварительными и согласуются с логикой Part 1: SFT формирует стартовую политику, но для корректного сравнения трёх режимов необходимы завершённые RL-ветки и агрегирование по нескольким seed.

План завершения Part 2:

1. досчитать GRPO (action) до целевого числа updates;
2. выполнить GRPO (text+action) в том же бюджете;
3. запустить multi-seed (не менее 5 seed) и отчитаться по mean $\pm$ std;
4. посчитать sample efficiency до фиксированного порога (например, success rate ≥ 0.80);
5. обновить итоговые таблицы и кривые в финальной версии отчёта.